

《大语言模型：从原理到应用》期末 Project

基于 OpenClaw / DeepScientist 的科研 Agent 功能扩展与缺陷诊断

作业 4 要求同学们完成一个能够通过 QQ 或 WeChat 进行自由交流的 LLM Agent，并提供真实部署、连接、测试与截图证据。期末 Project 不再仅考察基础部署，而是在作业 4 基础上进一步考察：你是否理解科研 Agent 的能力边界，能够通过功能扩展或系统实验展示其价值与不足。

一、Project 目标

本 Project 要求同学们基于 OpenClaw 或 DeepScientist 二选一，并允许在所选系统基础上进行二次开发，完成一个小的科研 Agent 项目。

核心目标包括：

1. 理解科研 Agent 的基本组成，包括任务理解、信息检索、工具调用、记忆管理、证据组织、报告生成与结果验证。
2. 认识现有科研 Agent 并不可靠地等同于“自动科学家”，其在证据使用、引用准确性、结论支撑、工具可靠性和多轮任务一致性方面仍可能存在问题。
3. 通过一个可运行功能或一组可复现实验，证明你对 Agent 系统能力边界的理解。
4. 训练同学们用真实交互、实验日志、对照结果和现场演示证明系统能力，而不是只依赖文字描述或静态截图。

期末 Project 只提供两个方向，学生从中选择一个完成即可，也可自行确立题目，须提前经任课教师确认。

二、Project 二选一方向

方向 A：科研智能体功能扩展（Engineering 赛道）

A.1 为科研智能体增加“证据链追踪模块”

1. 任务目标

科研 Agent 的一个常见问题是：它可能生成看似专业的报告，但用户难以判断哪些内容来自真实材料，哪些内容只是模型推断，哪些内容并没有证据支持。因此，本方向要求你让 Agent 的输出更加可追踪、可检查、可复现。

2. 具体要求

你需要为 OpenClaw 或 DeepScientist 搭建的科研 Agent 增加一个简单但可验证的“证据链追踪模块”。该模块的目标是：当 Agent 生成科研总结、实验建议、论文分析或报告时，能够为关键结论标注可检查的证据来源，而不是只给出泛泛引用。你需要实现或改造一个模块，使 Agent 至少能够完成以下功能：

1. 记录输入材料与工具输出来源，例如论文 PDF 页码、网页 URL、论文摘要、实验日志、代码运行 `stdout/stderr`、工具调用记录或结果表格。
2. 在生成报告时，为关键结论标注 `evidence id`，并说明其来源位置。
3. 区分三类内容：已有材料明确支持的结论；由模型合理推断但未被直接证明的内容；证据不足或需要进一步验证的内容。
4. 在 QQ 或 WeChat 真实交互中展示该功能。
5. 至少完成 5 个测试案例，其中至少 1 个为证据不足、引用错误、工具失败或边界案例。

3. 推荐实现方式

你可以采用简单实现，不要求复杂数据库系统。例如：

- 使用 JSON 文件或 Markdown 文件记录证据条目；
- 为每次检索、PDF 解析、代码运行或工具调用生成 `evidence id`；
- 在最终报告中加入 Evidence Table；
- 在 Agent prompt 中要求模型引用 `evidence id`；
- 对没有 `evidence id` 支持的结论进行标记；
- 使用规则、轻量脚本或人工检查判断输出是否符合要求。

4. 最低可接受成果

完成本方向的最低要求是：

1. 系统能够通过 QQ 或 WeChat 接收科研相关任务；
2. 系统能够处理至少一种输入材料，例如 PDF、网页文本、论文摘要或实验日志；
3. 系统输出报告时包含证据编号或证据表；
4. 报告中能够明确指出哪些结论有证据，哪些结论证据不足；
5. 提供扩展前后对比，说明加入证据链模块后输出质量有何变化。

方向 B：智能体框架缺陷诊断（Research 赛道）

B.1 科研报告生成中的“引用与结论不一致”实验

1. 任务目标

你需要设计一组实验，系统性测试 OpenClaw 或 DeepScientist 搭建的科研 Agent 在生成科研报告时是否存在“引用与结论不一致”的问题。

这里的“引用与结论不一致”是指：Agent 给出的结论看起来有引用或材料支持，但实际检查后发现引用材料并不能充分支持该结论，甚至与结论相矛盾。

本方向不要求修改 Agent 内部代码，但必须提供可复现的评测材料，包括测试样例、标注表、错误分类标准和统计脚本。实现 skill 或 API 可作为加分项，但不是最低要求。

2. 具体要求

你需要完成以下任务：

1. 准备至少 5 个科研报告生成任务。
2. 每个任务提供明确输入材料，例如论文摘要、论文片段、PDF、实验结果表格或相关工作材料。
3. 要求 Agent 基于输入材料生成一段科研报告，例如 related work、method summary、experiment analysis 或 limitation analysis。
4. 制作评测表或轻量脚本，辅助记录 Agent 输出中的关键结论、引用证据和人工判断。关键一致性判断可由人工依据统一标准完成。
5. 对不一致问题进行分类与统计。
6. 至少 1 个完整测试案例必须通过 QQ 或 WeChat 真实完成；其余案例可通过本地界面或脚本完成，但必须保留日志。

3. 错误类型分类

建议至少使用以下四类错误：

1. Unsupported Claim：结论没有被任何输入材料支持。
2. Overclaim：材料只支持较弱结论，但 Agent 写成了更强结论。
3. Mis-citation：引用材料与结论主题相关，但不能支持该具体结论。
4. Contradiction：Agent 的结论与材料内容相反或冲突。

4. 推荐实验记录格式

字段	内容
Case ID	测试样例编号
Input Material	输入材料来源或摘要
Agent Task	要求 Agent 完成的报告任务
Agent Claim	Agent 生成的关键结论
Cited Evidence	Agent 声称使用的证据
Human Judgment	人工判断：支持 / 部分支持 / 不支持 / 矛盾
Error Type	错误类型：Unsupported Claim / Overclaim / Mis-citation / Contradiction
Explanation	为什么认为该结论有问题

5. 最低可接受成果

完成本方向的最低要求是：

1. 至少完成 5 个测试样例；
2. 每个样例都包含输入材料、Agent 输出和人工判断；
3. 至少统计一种错误率，例如 unsupported claim rate 或 citation inconsistency rate；
4. 至少展示 2 个具体失败案例并解释失败原因；
5. 给出对 OpenClaw 或 DeepScientist 后续改进的建议。

三、提交要求

无论选择方向 A 还是方向 B，每个小组提交一份压缩包。最终提交的压缩包必须包括以下内容。

1. 项目报告（PDF 格式，不接受其余格式）

建议 6 到 10 页，包含：

1. 项目题目和选择方向：证据链追踪模块 或 引用与结论不一致实验；
2. 选择的基础系统：OpenClaw / DeepScientist / 改造版本；
3. 问题定义；
4. 系统设计或实验设计；
5. 测试样例；
6. 失败案例；
7. 局限性与未来改进；
8. 个人或小组贡献说明。

2. 代码、配置与数据（完整工程实现文件夹）

需要提交：

1. 源代码或实验脚本；
2. 关键配置文件；
3. 安装与启动说明；
4. 测试数据或测试样例；
5. 运行日志；
6. 现场展示所需的最小可运行版本，包括启动脚本、配置说明和测试入口；
7. 如果使用现有框架，必须说明你实际修改、配置或测试了哪些部分。

3. 证据材料（PDF 格式，不接受其余格式）

必须提交：

1. QQ 或 WeChat 真实交互截图；
2. Agent 后台运行截图；
3. 至少 5 个测试样例的输入与输出；
4. 至少 2 个失败案例或边界案例分析。

总计：2 份 PDF 格式文档，1 份实现代码和数据文件夹。请整理成一份压缩包，命名为 **Group01_LLM_Project_Engineering.zip** 或 **Group01_LLM_Project_Research.zip** （调整组队序号）

四、展示要求

现场展示是本 Project 的重要组成部分。展示时间建议为 10 分钟，问答 5 分钟，总计 15 分钟。

现场展示系统中必须包含：

1. 你选择的系统和方向；
2. 一个完整的 QQ 或 WeChat 交互过程；
3. 一个成功案例；
4. 一个失败案例或边界案例；
5. 对结果的简短解释；
6. 如果系统现场运行失败，需要展示提前准备好的日志、截图和录屏，并解释失败原因。若现场无法运行，但能提供完整录屏、日志和可复现材料，现场展示项最高不超过 20/30。

需要准备的材料：

1. 一份可以直接运行的系统，提前完成边界案例测试，并至少完整彩排一次现场展示流程；
2. 一个打印好的 Poster，建议尺寸为长 120cm × 宽 80cm。

五、Rubric 打分指南

总分 100 分，具体评分标准如下：

评分项	分值	评分说明
1. 问题定义与系统理解	15	是否清楚说明自己要解决什么问题；是否理解 OpenClaw / DeepScientist 作为 Agent 系统的基本结构；方向 A 重点看是否能说明该实现为什么重要，方向 B 重点看所指出的缺陷是否真实值得研究。
2. 功能实现或实验设计	25	方向 A 重点看工程模块是否真实可用；方向 B 重点看缺陷分析是否清晰、工具包是否可复现、有错误分类。
3. 结果证据与可复现性	15	是否提供 QQ/WeChat 交互截图、后台日志、测试样例、配置说明；他人是否基本能够复现。
4. 分析质量与失败案例	15	是否不仅展示成功结果，也分析失败案例；是否能够解释错误原因、系统局限与改进方向。
5. 现场展示与答辩	30	是否能现场展示完整流程；是否能清楚解释系统行为；是否能回答为什么结果可信；是否能展示成功案例和失败案例。

六、直接扣分或判零情况

以下情况将严重扣分或直接判为 0 分：

- 1. 伪造 QQ/WeChat 截图、日志或实验结果；
- 2. 直接复制他人代码、报告或官方文档作为自己的工作；
- 3. 大量使用大模型生成内容，但不能解释、验证或复现其中关键结果；
- 4. 不能说明自己实际完成了什么；
- 5. 没有任何真实交互证据、无代码或实验脚本、无运行日志、无可复现说明；
- 6. 只重复作业 4 的部署内容，没有功能扩展或缺陷诊断；
- 7. 报告中声称系统有效，但没有测试样例或证据支持。

七、作业提交截止日期

事项	截止时间	说明
Presentation Deadline	2026.06.05	课上按小组序号从小到大展示；Presentation 部分 30 分在展示当天评定。
Report Draft Deadline	2026.06.05	课上上课前需打印五份交给老师和助教。
Final Report Deadline	2026.06.08	根据 presentation 反馈调整；Final Report 用于评定其余 70 分。